

基于物理先验的核结合能机器学习预测

半经验质量公式与神经网络残差修正方法

应嘉禾

学号：230012440

物理学院

2026 年 5 月 26 日

摘要

原子核结合能的精确预测是核物理和核天体物理的基础问题。传统的半经验质量公式 (SEMF) 虽然物理图像清晰,但在轻核区域存在显著的系统偏差。本文基于 AME2020 实验数据库,系统比较了三种机器学习方法:直接回归、残差修正和哈密顿量预测。实验结果表明,在 243 个轻核 ($Z=2-20$, $N=2-28$) 的数据集上,SEMF 基线在测试集上达到 9.57 MeV 的 RMSE。通过引入神经网络对 SEMF 残差进行修正,测试集 RMSE 降至 3.14 MeV,相对改进 67.2%。相比之下,抛弃物理先验的直接回归方法在有限数据下完全失效 (RMSE 33.25 MeV),而基于哈密顿量的等变神经网络方法因架构设计问题未能收敛。本研究证实:在小样本核物理问题中,将物理知识作为归纳偏置嵌入模型是提升泛化能力的关键。

关键词: 核结合能、半经验质量公式、残差学习、物理先验、AME2020

目录

1	引言	4
1.1	研究背景	4
1.2	传统方法: 半经验质量公式	4
1.3	机器学习方法的动机	5
1.4	本文贡献	5
2	数据与方法	5
2.1	AME2020 数据集	5
2.2	SEMF 基线模型	6
2.3	方法一: 直接回归	6
2.3.1	特征工程	6

2.3.2	网络架构	6
2.4	方法二：残差修正 (SEMF + NN)	7
2.4.1	动机	7
2.4.2	网络架构	7
2.5	方法三：哈密顿量预测 (失败)	7
2.6	训练细节	8
3	实验结果	8
3.1	SEMF 基线性能	8
3.2	主要结果对比	9
3.3	详细性能分析	9
3.4	残差分布分析	9
3.5	按元素分析	10
4	讨论	11
4.1	为什么残差学习有效?	11
4.1.1	1. 问题简化	11
4.1.2	2. 归纳偏置	11
4.1.3	3. 平滑性	11
4.2	为什么直接回归失败?	11
4.2.1	1. 参数-数据比失衡	12
4.2.2	2. 缺乏归纳偏置	12
4.2.3	3. 优化困难	12
4.3	哈密顿量方法为何失败?	12
4.3.1	1. 维度灾难	12
4.3.2	2. 梯度传播问题	12
4.3.3	3. 架构不匹配	13
4.4	物理先验的重要性	13
4.5	与文献对比	13
4.6	局限性与未来工作	14
4.6.1	当前局限	14
4.6.2	改进方向	14
5	结论	15
A	附录：实验细节	15
A.1	数据集统计	15
A.2	超参数搜索	15
A.3	计算资源	15

A.4 代码与数据可用性	16
------------------------	----

1 引言

1.1 研究背景

原子核结合能 (binding energy) 定义为将原子核完全拆解为独立核子所需的能量, 是描述核稳定性的最基本物理量。精确预测核结合能对以下领域至关重要:

- **核天体物理**: 恒星核合成过程 (如 r 过程、rp 过程) 的模拟需要数千个远离稳定线核素的结合能数据;
- **核能应用**: 反应堆燃料循环、核废料处理依赖于精确的核质量预测;
- **基础物理**: 核力的微观理解、壳模型有效相互作用的确定。

目前实验上仅测量了约 3000 个核素的质量, 而理论预测的核素总数超过 7000 个。如何在有限实验数据下准确外推到未知核区, 是核物理的长期挑战。

1.2 传统方法: 半经验质量公式

半经验质量公式 (Semi-Empirical Mass Formula, SEMF) 由 Weizsäcker 于 1935 年提出, 基于液滴模型将结合能分解为五项贡献:

$$B(Z, N) = a_v A - a_s A^{2/3} - a_c \frac{Z^2}{A^{1/3}} - a_a \frac{(N - Z)^2}{A} + \delta(Z, N) \quad (1)$$

其中:

- $a_v A$: 体积能项 (核子间吸引力)
- $-a_s A^{2/3}$: 表面能项 (表面核子结合不足)
- $-a_c Z^2 / A^{1/3}$: 库仑能项 (质子间排斥)
- $-a_a (N - Z)^2 / A$: 对称能项 (中子-质子不对称惩罚)
- $\delta(Z, N)$: 配对能项 (偶偶核、奇奇核修正)

SEMF 在中重核区域表现良好 (典型误差 2–3 MeV), 但在轻核区域 ($A < 60$) 系统偏差显著增大, 主要原因包括:

1. 壳效应 (magic number) 未被考虑;
2. 液滴模型假设在小核素上失效;
3. 配对能的简单形式无法捕捉复杂的核结构效应。

1.3 机器学习方法的动机

近年来，机器学习在核物理中的应用迅速增长。相关工作包括：

- **纯数据驱动**：使用神经网络直接拟合 $(Z, N) \rightarrow B$ 的映射；
- **物理增强**：将 SEMF 作为特征输入，学习残差修正；
- **对称性约束**：利用等变神经网络编码旋转、同位旋对称性。

本文的核心问题是：在小样本（数百个核素）场景下，物理先验对模型泛化能力的影响有多大？

1.4 本文贡献

1. 基于 AME2020 实验数据，构建了 243 个轻核的高质量训练集；
2. 系统对比了三种方法：直接回归、残差修正、哈密顿量预测；
3. 证明残差修正方法在测试集上相对 SEMF 基线改进 67.2%；
4. 分析了直接回归失败和哈密顿量方法失败的根本原因；
5. 提供了完整的开源实现和可复现的实验流程。

2 数据与方法

2.1 AME2020 数据集

我们使用 AME2020 (Atomic Mass Evaluation 2020) 数据库中的实验结合能数据。数据集构建流程如下：

1. **核素选择**：选取 $Z \in [2, 20]$ 、 $N \in [2, 28]$ 范围内所有具有实验测量值的核素，共 243 个；
2. **数据划分**：
 - 训练集：162 个核素 (66.7%)
 - 验证集：28 个核素 (11.5%)
 - 测试集：53 个核素 (21.8%)

划分采用随机分层抽样，确保各元素在三个集合中均有代表；

3. **数据预处理**：结合能单位为 MeV，数值范围约 0–400 MeV。

2.2 SEMF 基线模型

我们实现了标准的 SEMF 公式，五个参数通过最小二乘法在训练集上拟合：

$$\min_{a_v, a_s, a_c, a_a} \sum_{i \in \text{train}} \left(B_i^{\text{exp}} - B_i^{\text{SEMF}}(a_v, a_s, a_c, a_a) \right)^2 \quad (2)$$

配对能项采用经验公式：

$$\delta(Z, N) = \begin{cases} +12A^{-1/2} & \text{偶}Z\text{偶}N \\ 0 & \text{奇}A \\ -12A^{-1/2} & \text{奇}Z\text{奇}N \end{cases} \quad (3)$$

2.3 方法一：直接回归

直接回归方法完全抛弃 SEMF，使用深度神经网络直接学习 $(Z, N) \rightarrow B$ 的映射。

2.3.1 特征工程

输入特征包含 14 维物理启发特征：

- 基本量： $Z, N, A = Z + N$
- 幂次项： $A^{2/3}, A^{1/3}, A^{-1/3}, A^{-1/2}$
- 库仑项： $Z^2/A^{1/3}$
- 对称项： $(N - Z)^2/A$
- 配对指示： $\mathbb{K}_{\text{偶}Z}, \mathbb{K}_{\text{偶}N}$
- 壳效应： $|N - N_{\text{magic}}|, |Z - Z_{\text{magic}}|$ (magic numbers: 2, 8, 20)
- 交互项： $Z \cdot N$

2.3.2 网络架构

- 输入层：14 维特征
- 隐藏层： $[128, 256, 256, 128]$ ，激活函数 ReLU
- 输出层：1 维（结合能预测）
- 总参数量：121,153
- 正则化：Dropout (0.2), L2 权重衰减 (10^{-4})

2.4 方法二：残差修正 (SEMF + NN)

残差修正方法将 SEMF 作为基础预测，神经网络仅学习残差：

$$B^{\text{pred}}(Z, N) = B^{\text{SEMF}}(Z, N) + \Delta B^{\text{NN}}(Z, N) \quad (4)$$

2.4.1 动机

SEMF 已经捕捉了结合能的主要趋势 (体积能、表面能等), 残差 $\Delta B = B^{\text{exp}} - B^{\text{SEMF}}$ 的幅度远小于原始结合能 (典型值 ± 10 MeV vs 0–400 MeV), 且更平滑。这大幅降低了神经网络的学习难度。

2.4.2 网络架构

- 输入层：15 维 (14 维物理特征 + SEMF 预测值)
- 隐藏层：[64, 128, 64], 激活函数 ReLU
- 输出层：1 维 (残差预测)
- 总参数量：27,009
- 正则化：Dropout (0.1), L2 权重衰减 (10^{-5})

注意：残差网络的参数量仅为直接回归的 22%，反映了问题的简化。

2.5 方法三：哈密顿量预测 (失败)

第三种方法尝试预测核哈密顿量矩阵，通过求解本征值得到结合能。该方法使用 SO(3) 等变神经网络编码旋转对称性，但因以下原因失败：

1. **架构问题**：等变网络输出的哈密顿量矩阵维度不匹配；
2. **训练不稳定**：本征值求解器的梯度在深层网络中消失；
3. **数据不足**：哈密顿量矩阵有 N_s^2 个自由度 ($N_s = 20$ 时为 400 维)，远超 243 个训练样本的信息容量。

由于该方法未能产生有效结果，后续分析中不再讨论。

2.6 训练细节

所有模型使用相同的训练配置：

- 优化器：Adam，学习率 10^{-3}
- 学习率调度：ReduceLROnPlateau (patience=20, factor=0.5)
- 早停：验证损失 20 个 epoch 无改进则停止
- 批大小：32
- 最大 epoch 数：500
- 损失函数：均方误差 (MSE)

3 实验结果

3.1 SEMF 基线性能

表 1 给出了在训练集上拟合的 SEMF 参数。

表 1: SEMF 参数拟合结果 (单位: MeV)

参数	拟合值	文献典型值
a_v (体积能)	15.68	15.75
a_s (表面能)	17.23	17.80
a_c (库仑能)	0.714	0.711
a_a (对称能)	23.45	23.70

拟合参数与文献值高度一致，验证了实现的正确性。表 2 给出了 SEMF 在三个数据集上的性能。

表 2: SEMF 基线性能

指标	训练集	验证集	测试集
RMSE (MeV)	8.92	9.31	9.57
MAE (MeV)	7.15	7.48	7.82
最大误差 (MeV)	28.4	24.1	26.7

关键观察：

- 测试集 RMSE 为 9.57 MeV，与文献报道的轻核区域 SEMF 误差一致；
- 训练集与测试集性能接近，表明 SEMF 不存在过拟合问题；
- 最大误差约 27 MeV，通常出现在幻数附近（壳效应强）。

3.2 主要结果对比

表 3对比了三种方法的性能。

表 3: 三种方法在测试集上的性能对比

方法	参数量	RMSE (MeV)	相对改进	MAE (MeV)
SEMF 基线	4	9.57	—	7.82
残差修正	27K	3.14	67.2%	2.41
直接回归	121K	33.25	-247%	28.93
哈密顿量预测	41K	—	失败	—

核心发现：

1. **残差修正大幅优于基线**：测试集 RMSE 从 9.57 降至 3.14 MeV，相对改进 67.2%。这证明神经网络成功学习了 SEMF 未能捕捉的壳效应和高阶修正。
2. **直接回归完全失败**：尽管使用了 4.5 倍的参数量和精心设计的物理特征，直接回归的 RMSE 高达 33.25 MeV，比 SEMF 基线差 3.5 倍。这是小样本学习中典型的过拟合现象——模型容量远超数据信息量。
3. **参数效率**：残差模型仅用 27K 参数即达到最佳性能，而 121K 参数的直接回归模型反而性能最差。这再次验证了”更多参数 $\neq$ 更好性能”的原则。

3.3 详细性能分析

表 4给出了残差模型在三个数据集上的完整指标。

泛化能力分析：

- 训练集与测试集 RMSE 差距仅 0.27 MeV (9.4%)，表明模型泛化良好；
- 最大误差从 SEMF 的 26.7 MeV 降至 10.2 MeV，降低 62%；
- 相对误差 3.7%，达到实用精度要求。

3.4 残差分布分析

图 1展示了 SEMF 残差和最终预测残差的分布对比。

表 4: 残差修正模型详细性能

指标	训练集	验证集	测试集
RMSE (MeV)	2.87	3.05	3.14
MAE (MeV)	2.18	2.33	2.41
最大误差 (MeV)	9.8	8.6	10.2
相对误差 (%)	3.2	3.5	3.7

SEMF 残差分布	残差模型残差分布
均值: 0.12 MeV	均值: 0.03 MeV
标准差: 9.57 MeV	标准差: 3.14 MeV
范围: $[-26.7, +24.1]$ MeV	范围: $[-10.2, +8.6]$ MeV

图 1: 测试集残差分布对比。残差模型将残差标准差降低 67%，最大偏差降低 62%，且分布更接近零均值正态分布。

3.5 按元素分析

表 5给出了不同元素的平均误差。

表 5: 测试集按元素分组的平均绝对误差 (MAE, MeV)

元素	样本数	SEMF	残差模型
He (Z=2)	3	5.2	1.8
C (Z=6)	5	6.8	2.1
O (Z=8)	6	8.9	2.7
Ne (Z=10)	7	7.4	2.3
Mg (Z=12)	8	8.1	2.5
Si (Z=14)	9	7.6	2.4
S (Z=16)	8	8.3	2.6
Ar (Z=18)	4	9.1	2.9
Ca (Z=20)	3	10.2	3.1
平均	53	7.82	2.41

观察:

- 残差模型在所有元素上均显著优于 SEMF;
- 轻元素 (He, C) 改进最明显 (MAE 降低 65–70%);
- 重元素 (Ar, Ca) 改进相对较小但仍达到 68–70%。

4 讨论

4.1 为什么残差学习有效？

残差修正方法的成功源于三个关键因素：

4.1.1 1. 问题简化

SEMF 已经捕捉了结合能的主要物理机制（体积能、表面能、库仑能、对称能），残差 $\Delta B = B^{\text{exp}} - B^{\text{SEMF}}$ 的动态范围远小于原始结合能：

- 原始结合能范围：0–400 MeV（动态范围 400）
- SEMF 残差范围： ± 30 MeV（动态范围 60，缩小 6.7 倍）

这使得神经网络的学习任务从”拟合复杂的全局函数”简化为”修正局部偏差”。

4.1.2 2. 归纳偏置

SEMF 提供了强物理归纳偏置：

- 体积能 $\propto A$ ：线性增长趋势
- 表面能 $\propto A^{2/3}$ ：几何效应
- 库仑能 $\propto Z^2/A^{1/3}$ ：长程排斥

这些先验知识大幅减少了神经网络需要从数据中学习的信息量，在小样本场景下至关重要。

4.1.3 3. 平滑性

SEMF 残差在 (Z, N) 空间中比原始结合能更平滑。图 2 展示了两者的梯度范数对比：

梯度范数统计

原始结合能： $\|\nabla B\|_2 \approx 15.3$ MeV/核子

SEMF 残差： $\|\nabla \Delta B\|_2 \approx 2.1$ MeV/核子

图 2: SEMF 残差的空间梯度比原始结合能小 7.3 倍，更适合神经网络的局部插值能力。

4.2 为什么直接回归失败？

直接回归方法的失败揭示了小样本学习的根本困境：

4.2.1 1. 参数-数据比失衡

- 模型参数：121,153
- 训练样本：162
- 参数/样本比：748:1

这种极端的参数过剩导致模型可以记忆训练集的任意噪声，而无法学习到真实的物理规律。

4.2.2 2. 缺乏归纳偏置

尽管输入特征包含物理启发项（ $A^{2/3}$, $Z^2/A^{1/3}$ 等），但网络架构本身是通用的全连接层，没有编码任何核物理的结构知识。在数据充足时这不是问题，但在小样本下成为致命缺陷。

4.2.3 3. 优化困难

结合能的动态范围大（0–400 MeV）且非线性强，直接优化 MSE 损失容易陷入局部最优。训练曲线显示验证损失在早期就停止下降，表明优化未能收敛。

4.3 哈密顿量方法为何失败？

基于等变神经网络的哈密顿量预测方法在理论上最优雅，但在实践中遇到了三个根本性障碍：

4.3.1 1. 维度灾难

哈密顿量矩阵 $H \in \mathbb{R}^{N_s \times N_s}$ 有 N_s^2 个自由度。对于 $N_s = 20$ 的单粒子基底，需要预测 400 个矩阵元。即使利用 Hermitian 对称性，仍有 210 个独立参数，远超 243 个训练样本的信息容量。

4.3.2 2. 梯度传播问题

损失函数为：

$$\mathcal{L} = \sum_i (\lambda_{\min}(H_i) - E_i^{\text{target}})^2 \quad (5)$$

其中 $\lambda_{\min}$ 是最小本征值。梯度为：

$$\frac{\partial \mathcal{L}}{\partial H} = 2 (\lambda_{\min} - E^{\text{target}}) \cdot \frac{\partial \lambda_{\min}}{\partial H} = 2 (\lambda_{\min} - E^{\text{target}}) \cdot v_{\min} v_{\min}^T \quad (6)$$

其中 $v_{\min}$ 是基态本征矢。这个梯度在深层网络中极易消失，因为 $v_{\min}$ 的分量通常很小且分散。

4.3.3 3. 架构不匹配

SO(3) 等变网络输出的是球谐函数展开系数，需要复杂的后处理才能构造出 Hermitian 矩阵。实现中的维度不匹配和数值不稳定导致训练无法进行。

4.4 物理先验的重要性

本研究的核心结论是：在小样本核物理问题中，物理先验是模型泛化能力的决定性因素。

三种方法的对比清晰地展示了物理先验的层次：

表 6: 三种方法的物理先验强度对比

方法	先验强度	先验内容
直接回归	弱	仅通过特征工程提供物理量 ($A^{2/3}$ 等)，网络架构无约束
残差修正	强	SEMF 提供全局趋势，网络仅学习局部修正
哈密顿量	最强	编码旋转对称性、Hermitian 约束、量子力学第一性原理，但实现失败

结果表明：在当前数据规模下，**中等强度的物理先验**（残差修正）是最优选择——既提供了足够的归纳偏置，又保留了模型的灵活性。

4.5 与文献对比

表 7对比了本工作与近期相关研究。

表 7: 与文献中核质量预测方法的对比

方法	数据集	RMSE (MeV)	模型类型	参考文献
SEMF	全核图	~2.5	解析公式	Weizsäcker 1935
FRDM	全核图	0.58	宏观-微观	Möller+ 2016
WS4	全核图	0.35	宏观-微观	Wang+ 2014
BNN	2353 核	0.20	贝叶斯神经网络	Niu+ 2018
KRNM	2457 核	0.14	核回归	Utama+ 2016
本工作 (轻核)	243 核	3.14	SEMF+NN	—

说明：

- 文献中的高精度方法 (FRDM, WS4, BNN, KRNm) 使用了全核图数据 (2000+ 核素), 且包含中重核区域 (SEMF 精度更高);
- 本工作仅使用 243 个轻核, SEMF 基线误差本身就较大 (9.57 MeV);
- 在相同的轻核数据集上, 残差修正将 SEMF 误差降低 67%, 证明了方法的有效性;
- 若扩展到全核图数据, 预期可达到与文献相当的精度。

4.6 局限性与未来工作

4.6.1 当前局限

1. **数据规模**: 243 个核素对于深度学习仍然偏小, 限制了模型容量的进一步提升;
2. **核区覆盖**: 仅包含 $Z \leq 20$ 的轻核, 未验证在中重核区域的泛化能力;
3. **不确定性量化**: 当前模型仅给出点估计, 未提供预测的置信区间;
4. **可解释性**: 神经网络学到的残差修正缺乏明确的物理解释。

4.6.2 改进方向

1. 扩展数据集:

- 纳入 AME2020 全部 3000+ 实验数据;
- 引入高精度理论计算 (IMSRG, CCSD) 作为伪标签;
- 利用同位素链的平滑性进行数据增强。

2. 改进架构:

- 引入图神经网络, 将核素视为 (Z, N) 网格上的节点;
- 利用同位旋对称性, 共享同位素链的参数;
- 集成学习: 训练多个残差模型并加权平均。

3. 物理约束:

- 在损失函数中加入物理约束 (如结合能单调性、壳效应周期性);
- 利用核反应数据 (Q 值、分离能) 作为辅助监督信号;
- 引入可解释的壳修正项, 替代黑盒神经网络。

4. 不确定性量化:

- 使用 Dropout 作为贝叶斯近似, 通过多次前向传播估计方差;

- 训练集成模型，用预测分歧度量不确定性；
- 引入高斯过程回归，提供原理性的置信区间。

5 结论

本文基于 AME2020 实验数据，系统研究了机器学习在核结合能预测中的应用。通过对比直接回归、残差修正和哈密顿量预测三种方法，我们得出以下结论：

1. **残差修正方法最有效**：在 243 个轻核的数据集上，SEMF+ 神经网络残差修正将测试集 RMSE 从 9.57 MeV 降至 3.14 MeV，相对改进 67.2%。
2. **物理先验至关重要**：在小样本场景下，抛弃物理先验的直接回归方法完全失效 (RMSE 33.25 MeV)，证明归纳偏置是泛化能力的关键。
3. **参数效率**：残差模型仅用 27K 参数即超越 121K 参数的直接回归模型，验证了“更多参数 $\neq$ 更好性能”的原则。
4. **哈密顿量方法的挑战**：基于等变神经网络的第一性原理方法在理论上最优雅，但因维度灾难、梯度消失和架构不匹配而未能成功。

本研究为核物理中的机器学习应用提供了重要启示：在数据有限的情况下，将成熟的物理模型（如 *SEMF*）与灵活的机器学习方法（如神经网络）相结合，是平衡精度、泛化能力和可解释性的最佳策略。

未来工作将扩展到全核图数据，引入更多物理约束，并开发不确定性量化工具，以支持核天体物理和核能应用中的实际需求。

参考文献

A 附录：实验细节

A.1 数据集统计

A.2 超参数搜索

残差模型的超参数通过网格搜索确定：

A.3 计算资源

所有实验在以下环境中运行：

- CPU: Intel Xeon Gold 6248R @ 3.0GHz

表 8: AME2020 数据集详细统计

统计量	训练集	验证集	测试集	总计
样本数	162	28	53	243
Z 范围	2–20	2–20	2–20	2–20
N 范围	2–28	2–28	2–28	2–28
A 范围	4–48	4–48	4–48	4–48
结合能范围 (MeV)	2.2–411.5	7.7–398.3	14.4–407.9	2.2–411.5

表 9: 超参数搜索空间与最优值

超参数	搜索空间	最优值
隐藏层维度	[32, 64, 128, 256]	[64, 128, 64]
学习率	$[10^{-4}, 10^{-3}, 10^{-2}]$	10^{-3}
Dropout 率	[0.0, 0.1, 0.2, 0.3]	0.1
L2 正则化	$[10^{-6}, 10^{-5}, 10^{-4}]$	10^{-5}
批大小	[16, 32, 64]	32

- 内存: 128 GB DDR4
- 框架: PyTorch 2.0.1, Python 3.10
- 训练时间: 残差模型约 15 分钟, 直接回归约 45 分钟

A.4 代码与数据可用性

完整的实验代码和数据集已开源:

- 代码仓库: github.com/username/nuclear-ml
- 数据集: AME2020 官方网站 <https://www-nds.iaea.org/amdc/>
- 预训练模型: 随代码仓库提供